

ANO
2025



UNINTER

**CADERNO DE RESPOSTAS DA
ATIVIDADE PRÁTICA DE:**

PROJETOS BIG DATA

**ALUNO: VICTOR GABRIEL MOREIRA - RU:
4655363**

**Caderno de Resposta Elaborado por:
Prof. MSc. Guilherme Ditzel Patriota**

Prática 01 – Somatório de Ids

Questão – Qual o valor da soma de todos os campos “id” dos filmes classificados como negativos para o banco de dados “imdb-reviews-pt-br.csv”

ENUNCIADO: Nessa prática você deverá descobrir, utilizando sua máquina virtual com o Hadoop ou Spark ou PySpark, qual o valor da soma de todos os campos “id” dos filmes classificados como negativos para o banco de dados “imdb-reviews-pt-br.csv”.

I. Apresentação do Código (não esquecer do identificador pessoal):

```

1  from pyspark.sql import SparkSession
2
3  # Identificador
4  ru4655363 = 4655363 # RU
5
6  # Inicializa sessão Spark
7  spark = SparkSession.builder \
8      .appName("Trabalho Big Data") \
9      .getOrCreate()
10
11 print(f"RU: {ru4655363}")
12
13 # Leitura do dataset
14 print("Carregando dataset...")
15 df = spark.read.csv(
16     "/data/IMDb-reviews-pt-br.csv",
17     header=True,
18     quote='"',
19     escape='\',
20     encoding="UTF-8"
21 )
22
23 df.show(5)
24
25 # QUESTÃO 1: Soma dos IDs negativos
26 def map1(x):
27     return x[3], int(x[0])
28
29 def reduceByKey1(x, y):
30
31     return x + y
32
33 resultado1 = df.rdd.map(map1).reduceByKey(reduceByKey1).collect()
34 print("\nQuestão 1 - Soma dos IDs:")
35 print(resultado1)
36
37 # QUESTÃO 2: Diferença de contagem de palavras
38 def map2(x):
39     return x[3], (len(x[1].split()), len(x[2].split()))
40
41 def reduceByKey2(x, y):
42     return (x[0] + y[0], x[1] + y[1])
43
44 resultado2 = df.rdd.map(map2).reduceByKey(reduceByKey2).collect()
45 print("\nQuestão 2 - Contagem de palavras:")
46 print(resultado2)
47
48 for sentimento, (en, pt) in resultado2:
49     if sentimento == "neg":
50         diferenca = pt - en
51         print(f"Diferença (PT - EN) para textos negativos: {diferença}")
52
53 spark.stop()

```

Figura 1: Script/Código em PySpark.

II. Apresentação das Imagens/Print do resultado (não esquecer do identificador):

[illegible]

Figura 2: Resultado do somatório de todos os campos “id” dos filmes classificados como negativos, feito com PySpark, no cluster Spark/Hadoop, em containers Docker.

III. Responda à pergunta: Qual o valor da soma de todos os campos “id” dos filmes classificados como negativos?

Resposta: O valor da soma de todos os campos "id" dos filmes classificados como negativos é de 459.568.555.

Prática 02 – Diferença do número de palavras totais de português para inglês dos textos negativos

Questão – Contar palavras dos textos negativos e achar diferença de quantidade.

ENUNCIADO: Nessa prática você deverá contar todas as palavras existentes nos textos negativos (Português e Inglês) e então deverá encontrar quantas palavras a mais, no total, os textos em português possuem.

Para tal, crie um script em Python ou Scala e rode-o com sua máquina virtual Hadoop ou Spark ou PySpark, como feito na prática 1.

É necessário se preocupar em filtrar corretamente as avaliações de filmes para que apenas os textos marcados como negativos sejam contabilizados.

I. Apresentação do Código (não esquecer do identificador pessoal):

```
trabalho_bigdata.py
1 from pyspark.sql import SparkSession
2
3 # Identificador
4 ru4655363 = 4655363 # RU
5
6 # Inicializa sessão Spark
7 spark = SparkSession.builder \
8     .appName("Trabalho Big Data") \
9     .getOrCreate()
10
11 print(f"RU: {ru4655363}")
12
13 # Leitura do dataset
14 print("Carregando dataset...")
15 df = spark.read.csv(
16     "/data/jmb-reviews-pt-br.csv",
17     header=True,
18     quote='"',
19     escape='\',
20     encoding="UTF-8"
21 )
22
23 df.show(5)
24
25 # Questão 1: Soma dos IDs negativos
26 def map1(x):
27     return (x[3], int(x[0]))
28
29 def reduceByKey1(x, y):
30     return x + y
31
32 resultado1 = df.rdd.map(map1).reduceByKey(reduceByKey1).collect()
33 print("\nQuestão 1 - Soma dos IDs:")
34 print(resultado1)
35
36 # Questão 2: Diferença de contagem de palavras
37 def map2(x):
38     return (x[3], (len(x[1].split()), len(x[2].split())))
39
40 def reduceByKey2(x, y):
41     return (x[0] + y[0], x[1] + y[1])
42
43 resultado2 = df.rdd.map(map2).reduceByKey(reduceByKey2).collect()
44 print("\nQuestão 2 - Contagem de palavras:")
45 print(resultado2)
46
47 for sentimento, (en, pt) in resultado2:
48     if sentimento == "neg":
49         diferenca = pt - en
50         print(f"Diferença (PT - EN) para textos negativos: {diferenca}")
51
52 spark.stop()
```

Figura 3: Script/Código em PySpark.

II. Apresentação das Imagens/Print do resultado (não esquecer do identificador):

```
25/10/23 12:25:00 INFO BlockManagerMasterEndpoint: Using org.apache.spark.storage.DefaultTopologyMapper for getting topology information
25/10/23 12:25:00 INFO BlockManagerMasterEndpoint: BlockManagerMasterEndpoint up
25/10/23 12:25:00 INFO SparkEnv: Registering BlockManagerMasterHeartbeat
25/10/23 12:25:00 INFO DiskBlockManager: Created local directory at /tmp/blockmgr-e157c9c4-de33-4715-9d4b-450fcc2f5b7a
25/10/23 12:25:00 INFO MemoryStore: MemoryStore started with capacity 434.4 MiB
25/10/23 12:25:00 INFO SparkEnv: Registering OutputCommitCoordinator
25/10/23 12:25:01 INFO NetUtils: Start Jetty 9.0.0.v20180801 for sparkUI
25/10/23 12:25:01 INFO Utils: Successfully started service 'SparkUI' on port 4040.
25/10/23 12:25:01 INFO Executor: Starting executor ID driver on host e0f8fba0921
25/10/23 12:25:01 INFO Executor: OS info Linux, 6.4.87.2-microsoft-standard-WSL2, amd64
25/10/23 12:25:01 INFO Executor: Java version 11.0.20.1
25/10/23 12:25:01 INFO Executor: Starting executor with user classpath (userClassPathFirst = false): ''
25/10/23 12:25:01 INFO Executor: Created or updated repl class loader org.apache.spark.util.MutableURLClassLoader@428312ba for default.
25/10/23 12:25:01 INFO Utils: Successfully started service 'org.apache.spark.network.netty.NettyBlockTransferService' on port 34725.
25/10/23 12:25:01 INFO NettyBlockTransferService: Server created on e0f8fba0921:34725
25/10/23 12:25:01 INFO BlockManager: Using org.apache.spark.storage.RandomBlockReplicationPolicy for block replication policy
25/10/23 12:25:01 INFO BlockManagerMaster: Registering BlockManager BlockManagerId(driver, e0f8fba0921, 34725, None)
25/10/23 12:25:01 INFO BlockManagerMasterEndpoint: Registering block manager e0f8fba0921:34725 with 434.4 MiB RAM, BlockManagerId(driver, e0f8fba0921, 34725, None)
25/10/23 12:25:01 INFO BlockManager: Registered BlockManager BlockManagerId(driver, e0f8fba0921, 34725, None)
25/10/23 12:25:01 INFO BlockManager: Initialized BlockManager: BlockManagerId(driver, e0f8fba0921, 34725, None)
25/10/23 12:25:01 INFO SparkContext: Setting hive.metastore.warehouse.dir ('null') to the value of spark.sql.warehouse.dir.
25/10/23 12:25:01 INFO SparkContext: Warehouse path is 'file:/opt/spark-warehouse/'.
25/10/23 12:25:01 INFO InMemoryFileIndex: It took 193 ms to list leaf files for 1 paths.
25/10/23 12:25:01 INFO InMemoryFileIndex: It took 11 ms to list leaf files for 1 paths.
25/10/23 12:25:01 INFO FileSourceStrategy: Pushed filters:
25/10/23 12:25:01 INFO FileSourceStrategy: Post-Scan Filters: (length(trim(value@, None)) > 0)
25/10/23 12:25:01 INFO PythonRunner: Times: total = 44, boot = -226, init = 863, finish = 7
25/10/23 12:25:01 INFO PythonRunner: Times: total = 79, boot = -1057, init = 1126, finish = 1
25/10/23 12:25:01 INFO PythonRunner: Times: total = 72, boot = -340, init = 909, finish = 3
25/10/23 12:25:01 INFO Executor: Finished task 2.0 in stage 5.0 (TID 10). 2014 bytes result sent to driver
25/10/23 12:25:01 INFO Executor: Finished task 1.0 in stage 5.0 (TID 17). 2057 bytes result sent to driver
25/10/23 12:25:01 INFO Executor: Finished task 0.0 in stage 5.0 (TID 14). 2115 bytes result sent to driver
25/10/23 12:25:01 INFO Executor: Finished task 1.0 in stage 5.0 (TID 15). 2115 bytes result sent to driver
25/10/23 12:25:01 INFO TaskSetManager: Finished task 1.0 in stage 5.0 (TID 15) in 320 ms on e0f8fba0921 (executor driver) (1/4)
25/10/23 12:25:01 INFO TaskSetManager: Finished task 3.0 in stage 5.0 (TID 17) in 311 ms on e0f8fba0921 (executor driver) (2/4)
25/10/23 12:25:01 INFO TaskSetManager: Finished task 2.0 in stage 5.0 (TID 10) in 321 ms on e0f8fba0921 (executor driver) (3/4)
25/10/23 12:25:01 INFO TaskSetManager: Finished task 0.0 in stage 5.0 (TID 14) in 332 ms on e0f8fba0921 (executor driver) (4/4)
25/10/23 12:25:01 INFO TaskSchedulerImpl: Removed TaskSet 5.0, whose tasks have all completed, from pool
25/10/23 12:25:01 INFO DAGScheduler: ResultStage 5 (collect at /scripts/trabalho_bigdata.py:43) finished in 0.468 s
25/10/23 12:25:01 INFO DAGScheduler: Job 3 is finished. Cancelling potential speculative or zombie tasks for this job
25/10/23 12:25:01 INFO TaskSchedulerImpl: Killing all running tasks in stage 5: Stage finished
25/10/23 12:25:01 INFO DAGScheduler: Job 3 finished: collect at /scripts/trabalho_bigdata.py:43, took 14.005614 s

Questão 2 - Contagem de palavras:
[('neg', (5400324, 5455273)), ('pos', (5414747, 5462204))]

Diferença (PT - EN) para textos negativos: 54949
25/10/23 12:26:24 INFO SparkContext: SparkContext is stopping with exitCode 0.
25/10/23 12:26:24 INFO SparkUI: Stopped Spark web UI at http://e0f8fba0921:4040
25/10/23 12:26:24 INFO MapOutputTrackerMasterEndpoint: MapOutputTrackerMasterEndpoint stopped!
25/10/23 12:26:24 INFO MemoryStore: MemoryStore cleared
25/10/23 12:26:24 INFO BlockManager: BlockManager stopped
25/10/23 12:26:24 INFO BlockManagerMaster: BlockManagerMaster stopped
25/10/23 12:26:24 INFO OutputCommitCoordinator: OutputCommitCoordinator stopped!
25/10/23 12:26:24 INFO SparkContext: Successfully stopped SparkContext
25/10/23 12:26:25 INFO ShutdownHookManager: Shutdown hook called
25/10/23 12:26:25 INFO ShutdownHookManager: Deleting directory /tmp/spark-6daf0412-eb7a-414d-94da-81fde555eef
25/10/23 12:26:25 INFO ShutdownHookManager: Deleting directory /tmp/spark-c38578fd-017c-484d-87cb-823a08bca34b/pyspark-a1dbd35-9935-429b-89ae-0659302ff865
25/10/23 12:26:25 INFO ShutdownHookManager: Deleting directory /tmp/spark-c38578fd-017c-484d-87cb-823a08bca34b
c:\Users\Victor\bigdata_trabalho
```

Figura 4: Resultado da contagem de todas as palavras existentes nos textos negativos (Português e Inglês) e quantas palavras a mais, no total, os textos em português possuem, feito com PySpark, no cluster Spark/Hadoop, em containers Docker.

III. Responda à pergunta: Qual o número total de palavras a mais que os textos negativos em português possuem em comparação com a soma total das palavras dos textos negativos em inglês, independentemente de serem repetidas?

Resposta: O total de palavras a mais que os textos negativos em português possuem em comparação com os textos negativos em inglês é de 54.949.